



Facultad de Ingeniería
Visión por Computadora

Proyecto – Entrega 1: Propuesta

LoveDA: Land-Cover Semantic Segmentation

Integrantes:
Jorge Butto Cumsille
Alvaro Toro Herrera

Profesor:
Billy Peralta

Santiago, Chile
2026

Resumen

El presente proyecto aborda un problema de segmentación semántica multiclase sobre imágenes aéreas de teledetección utilizando el dataset LoveDA. El objetivo general consiste en desarrollar posteriormente un sistema capaz de asignar a cada píxel una categoría de cobertura terrestre entre las clases background, building, road, water, barren, forest y agriculture, considerando el valor 0 de las máscaras como región no-data que debe ser ignorada durante la evaluación.

Como parte de esta primera entrega se desarrolló un proceso reproducible de descarga, lectura, validación y análisis exploratorio del conjunto de datos oficial. La ejecución permitió verificar 5.987 imágenes RGB de 1024×1024 píxeles y 4.191 máscaras semánticas disponibles localmente. El dataset se encuentra organizado en los conjuntos oficiales Train, Val y Test, y además distingue dos dominios: Urban y Rural.

El análisis incluyó la distribución de clases, presencia de categorías por imagen, porcentaje de píxeles no-data, diferencias entre dominios y comprobaciones de integridad y duplicados. No se detectaron problemas reales de corrupción, etiquetas inválidas ni duplicados exactos.

Para las etapas posteriores se propone mantener el conjunto Test oficial reservado para evaluación externa, utilizar una división reproducible dentro de Train para entrenamiento y ajuste, y conservar Val como evaluación local independiente. El desempeño se evaluará mediante IoU por clase, mIoU y Dice/F1. Como innovación se utilizará segmentación multiescala, comparando posteriormente sus resultados con el método base.

1. Introducción

La visión por computador busca obtener información con significado a partir de imágenes o videos. En el material introductorio del curso se plantea este desafío como la necesidad de superar la barrera entre los valores de los píxeles y la interpretación semántica de una escena.

Una de las tareas que permite realizar esta interpretación es la segmentación semántica. En este tipo de problema no se asigna una única etiqueta a una imagen completa, sino que cada píxel debe clasificarse según la categoría a la que pertenece. Esto permite obtener una representación espacial detallada de los distintos elementos presentes en la escena.

En este proyecto se trabajará con el dataset LoveDA, propuesto para tareas de segmentación semántica y adaptación de dominio en imágenes de teledetección. LoveDA contiene imágenes de alta resolución espacial provenientes de entornos urbanos y rurales y considera diferencias importantes en escala, fondo y distribución de clases entre ambos dominios. La documentación oficial reporta 5.987 imágenes provenientes de Nanjing, Changzhou y Wuhan, con una resolución espacial aproximada de 0,3 m [2].

El problema seleccionado corresponde al Tema 3 del proyecto de la asignatura: LoveDA: Land-Cover Semantic Segmentation, definido como una tarea de segmentación semántica multiclase de cobertura terrestre en imágenes aéreas.

Esta primera etapa se concentra en comprender y caracterizar correctamente los datos antes de implementar un modelo de segmentación. Para ello se desarrolló un notebook en Python que permite obtener el dataset oficial, validar imágenes y máscaras, analizar la distribución de clases y dominios, detectar posibles problemas de calidad y generar figuras y tablas reutilizables posteriormente en el informe.

LoveDA: muestra RGB aleatoria reproducible




Figura 1. Ejemplos de imágenes RGB pertenecientes a LoveDA. Se observan escenas de los dominios Urban y Rural con diferencias de apariencia y distribución espacial.

2. Definición del problema y objetivos

2.1 Definición del problema

El proyecto consiste en desarrollar un sistema de visión por computador capaz de realizar segmentación semántica multiclase sobre imágenes aéreas de teledetección del dataset LoveDA. Para cada píxel de una imagen, el sistema deberá determinar la categoría de cobertura terrestre correspondiente.

Las clases semánticas consideradas son background, building, road, water, barren, forest y agriculture. Adicionalmente, las máscaras pueden contener el valor 0, correspondiente a regiones no-data, las cuales no representan una clase semántica válida y deben ser ignoradas durante la evaluación. Esta definición coincide con la documentación oficial de LoveDA indica una resolución espacial aproximada de 0,3 m [2].

A diferencia de una tarea de segmentación binaria, en este problema el sistema debe distinguir simultáneamente múltiples categorías de cobertura terrestre. La dificultad aumenta debido a la variedad de escalas con que aparecen los elementos, las diferencias entre

entornos urbanos y rurales y la distribución desigual de las clases dentro del dataset. Los autores de LoveDA identifican precisamente como desafíos principales los objetos multiescala, los fondos complejos y las distribuciones de clases inconsistentes [2].

Una segmentación correcta de este tipo de imágenes puede ser útil en aplicaciones relacionadas con análisis territorial, planificación urbana, monitoreo de superficies y procesamiento automatizado de información geográfica obtenida mediante teledetección.

2.2 Objetivo general

Desarrollar y evaluar un sistema de visión por computador capaz de realizar segmentación semántica multiclase sobre imágenes aéreas de LoveDA, clasificando cada píxel válido según su categoría de cobertura terrestre.

2.3 Objetivos específicos

- Analizar y caracterizar la estructura real del dataset LoveDA.
- Implementar la lectura y validación de imágenes y máscaras semánticas.
- Identificar los splits oficiales y los dominios Urban y Rural.
- Analizar la distribución de las clases y su presencia en las imágenes.
- Verificar el tratamiento correcto de las regiones no-data.
- Diseñar una estrategia reproducible para entrenamiento, validación y evaluación.
- Implementar posteriormente un método base de segmentación semántica.
- Evaluar el desempeño futuro mediante IoU por clase, mIoU y Dice/F1.
- Incorporar posteriormente segmentación multiescala como innovación y comparar sus resultados con el método base.

3. Descripción y análisis del dataset

3.1 Fuente y estructura general

El dataset utilizado corresponde a LoveDA (LoveDA: A Remote Sensing Land-Cover Dataset for Domain Adaptive Semantic Segmentation), publicado por Wang et al. en 2021 [2]. El conjunto fue diseñado para tareas de segmentación semántica y adaptación de dominio en imágenes de teledetección, y sus archivos oficiales se encuentran disponibles a través de Zenodo [3].

Para este proyecto se descargaron las particiones oficiales Train, Val y Test. La integridad de los archivos oficiales descargados desde Zenodo fue comprobada mediante los tamaños y hashes MD5 publicados por la plataforma. Los valores volvieron a verificarse al finalizar el análisis, sin observarse modificaciones.

LoveDA se organiza en tres particiones principales: Train, Val y Test. Cada una de ellas separa las imágenes según los dominios Rural y Urban. Los conjuntos Train y Val incluyen tanto las imágenes RGB como sus respectivas máscaras de segmentación, mientras que Test contiene únicamente imágenes y no dispone de máscaras de referencia locales.

Esta característica del conjunto Test responde al esquema de evaluación definido para LoveDA: los modelos pueden desarrollarse utilizando los datos etiquetados de Train y Val, mientras que las predicciones realizadas sobre Test se destinan a una evaluación externa [4].

3.2 Cantidad de imágenes y máscaras

La ejecución del notebook identificó un total de 5.987 imágenes y 4.191 máscaras semánticas.

La diferencia entre ambas cantidades se debe a que las 1.796 imágenes pertenecientes al conjunto Test oficial no incluyen ground truth local. Esta ausencia corresponde al diseño original del dataset y no constituye un problema de integridad.

Tabla 1. Distribución por split

Split	Imágenes	Máscaras	Rural	Urban
Train	2.522	2.522	1.366	1.156
Val	1.669	1.669	992	677
Test	1.796	0	976	820
Total	5.987	4.191	3.334	2.653

Fuente: resultados obtenidos mediante 01_dataset_exploration.ipynb.




Figura 2. Distribución de imágenes entre los splits oficiales Train, Val y Test.

3.3 Dominios Urban y Rural

LoveDA distingue explícitamente dos dominios geográficos: Urban y Rural. La ejecución permitió identificar 3.334 imágenes Rural y 2.653 imágenes Urban.

Esta separación es relevante porque ambos dominios presentan composiciones visuales diferentes. Por ejemplo, el análisis posterior de las máscaras mostró una mayor representación relativa de clases como building y road en Urban, mientras que agriculture y forest presentan mayor participación relativa en Rural.




Figura 3. Distribución de imágenes entre los dominios Rural y Urban.

3.4 Resolución y formato

Todas las imágenes y máscaras legibles presentan una resolución de 1024×1024 píxeles.

Las imágenes se encuentran almacenadas en formato PNG y poseen tres canales en modo RGB. Las máscaras también se encuentran en formato PNG, pero utilizan un único canal, donde cada valor entero representa una clase semántica.

La documentación oficial de LoveDA indica una resolución espacial aproximada de 0,3 m. Sin embargo, durante el análisis se verificó que esta información no se encuentra almacenada como metadata geográfica dentro de los archivos PNG, por lo que dicho valor debe considerarse información proveniente de la documentación y no una característica recuperada directamente desde los archivos.

3.5 Clases semánticas y máscaras

La inspección de las máscaras confirmó la presencia exacta de los valores 0, 1, 2, 3, 4, 5, 6 y 7. No se detectaron valores inesperados.

Las clases válidas corresponden a:

Tabla 2. Etiquetas semánticas de LoveDA

Valor	Clase
0	no-data / ignore
1	background
2	building
3	road
4	water
5	barren
6	forest
7	agriculture

El valor 0 se conserva sin modificación y se excluye del conjunto de clases evaluadas. Las clases 1 a 7 constituyen las siete categorías semánticas del problema. Esta definición coincide con la documentación oficial del dataset [4].

LoveDA: RGB, etiquetas originales y superposición




Figura 4. Ejemplos de imagen RGB, máscara semántica de referencia y superposición entre ambas.

3.6 Distribución global de clases

Para caracterizar el balance de clases se contabilizaron los píxeles de todas las máscaras disponibles en Train y Val, excluyendo los píxeles con valor 0.

Sobre un total de 4.249.172.884 píxeles válidos, la categoría con mayor presencia corresponde a background, seguida de agriculture y forest. Las categorías menos representadas son barren y road.

Estos resultados muestran que la distribución de clases no es uniforme. Esta característica deberá considerarse posteriormente al seleccionar la función de pérdida, las estrategias de muestreo y las métricas utilizadas durante el entrenamiento.




Figura 5. Distribución porcentual por clase calculada sobre los píxeles válidos (1–7) y sobre el total de píxeles de las máscaras.

3.7 Presencia de clases por imagen

Además de analizar la cantidad total de píxeles, se calculó en cuántas de las 4.191 imágenes etiquetadas aparece cada clase.

Background se encuentra presente en aproximadamente el 98,09% de las imágenes, mientras que barren presenta la menor frecuencia de aparición, con aproximadamente 43,40%.




Figura 6. Porcentaje de imágenes etiquetadas en las que aparece cada clase semántica.

3.8 Número de clases presentes por imagen

Debido a que LoveDA corresponde a segmentación semántica y no a segmentación de instancias, no resulta apropiado interpretar las regiones conectadas como “objetos anotados”. En este caso, una medida más representativa consiste en analizar cuántas clases semánticas diferentes aparecen dentro de cada imagen.

En las imágenes con máscara se observaron entre 1 y 7 clases válidas, con un promedio aproximado de 4,95 clases por imagen y una mediana de 5.




Figura 7. Distribución del número de clases semánticas válidas presentes por imagen.

3.9 Regiones no-data

Las máscaras contienen regiones identificadas con valor 0, las cuales corresponden a no-data y deben ser ignoradas durante la evaluación.

En las 4.191 máscaras disponibles se contabilizaron 4.394.582.016 píxeles etiquetados, de los cuales 145.409.132 corresponden a no-data. Esto representa aproximadamente un 3,31% del total.

El porcentaje no es uniforme entre los subconjuntos y dominios. En Train corresponde aproximadamente a 3,77%, mientras que en Val es 2,62%. Al separar por dominio, Rural presenta aproximadamente 2,41% y Urban aproximadamente 4,47%.

El tratamiento correcto de estas regiones es importante porque incluirlas como una clase normal alteraría artificialmente tanto la distribución de datos como las métricas de evaluación.

3.10 Diferencias entre Urban y Rural

Uno de los principales aspectos de LoveDA es la diferencia de distribución entre los dominios Urban y Rural. Los resultados obtenidos muestran que esta diferencia es considerable en varias categorías [4].

Por ejemplo, building representa aproximadamente un 17,96% de los píxeles válidos en Urban, pero solamente un 3,09% en Rural. Una situación similar ocurre con road, con aproximadamente 8,72% en Urban y 2,22% en Rural.

Por el contrario, agriculture representa aproximadamente 33,34% de los píxeles válidos en Rural y 10,70% en Urban. También se observa una mayor proporción de forest en Rural.

Estos valores son descriptivos del dataset analizado y no implican relaciones causales. Sin embargo, muestran que los dominios presentan distribuciones diferentes, aspecto que deberá considerarse posteriormente durante el entrenamiento y evaluación.




Figura 8. Comparación de la distribución porcentual de clases válidas entre los dominios Urban y Rural.

3.11 Validación y calidad de los datos

Antes de utilizar el dataset en futuros experimentos se realizaron comprobaciones de integridad sobre imágenes, máscaras y emparejamientos. No se detectaron imágenes o máscaras corruptas, incompatibilidades de dimensiones, etiquetas inesperadas, máscaras completamente *no-data* ni duplicados exactos, tampoco entre los distintos splits. Las 1.796 imágenes pertenecientes al Test oficial no poseen máscaras de referencia locales; esta ausencia corresponde al diseño original de LoveDA y, por lo tanto, no fue considerada un problema de integridad. Los hashes SHA-256 utilizados permiten detectar archivos idénticos

byte a byte, pero no descartar imágenes visualmente similares o regiones geográficas cercanas.

4. Diseño experimental

4.1 Preparación de los datos

Antes de comenzar el entrenamiento de un modelo de segmentación será necesario preparar las imágenes y máscaras de forma consistente. LoveDA utiliza imágenes RGB de 1024×1024 píxeles y máscaras semánticas del mismo tamaño, por lo que cada transformación geométrica aplicada a una imagen deberá aplicarse también a su máscara correspondiente.

El valor 0 de las máscaras se mantendrá como región no-data y será excluido durante el cálculo de las métricas. Las etiquetas 1 a 7 se conservarán como las clases semánticas válidas del problema: background, building, road, water, barren, forest y agriculture. Este tratamiento coincide con la definición del problema establecida para el proyecto.

En esta primera entrega no se aplicó todavía redimensionamiento, normalización, data augmentation ni otras transformaciones asociadas al entrenamiento. Estas decisiones serán definidas una vez seleccionado el algoritmo base en la siguiente etapa del proyecto.

4.2 División Train / Validation / Test

LoveDA incluye tres particiones oficiales: Train, Val y Test. Sin embargo, el conjunto Test no posee máscaras de referencia disponibles localmente, por lo que no puede utilizarse para calcular directamente métricas como mIoU o Dice durante el desarrollo.

Por esta razón, se propone utilizar el conjunto Train oficial como conjunto de desarrollo. En una etapa posterior se realizará una división reproducible de Train en un 80% para entrenamiento interno y 20% para validación interna. El conjunto Val oficial se mantendrá completamente separado y se utilizará como evaluación local final.

Por su parte, Test se conservará sin modificaciones para una eventual evaluación externa mediante el procedimiento definido por LoveDA. La documentación oficial indica que los modelos pueden desarrollarse utilizando Train y Validation, mientras que los resultados de Test se evalúan mediante el challenge del dataset.

Esta estrategia permite disponer de datos para ajuste de hiperparámetros sin utilizar el conjunto Val oficial durante dicho proceso. La división interna deberá generarse con una semilla fija y procurando conservar de manera aproximada la proporción entre escenas Urban y Rural y la distribución de las clases.

Tabla 3. Protocolo experimental propuesto

Conjunto	Uso propuesto
Train oficial – 80%	Entrenamiento del modelo
Train oficial – 20%	Validación interna y ajuste
Val oficial	Evaluación local final
Test oficial	Evaluación externa

La división 80/20 todavía no se ha materializado, ya que corresponde al diseño de los experimentos futuros y no a un resultado de esta primera entrega.

4.3 Prevención de fuga de información

Como parte del análisis inicial se calcularon hashes SHA-256 de las imágenes y no se encontraron duplicados exactos, ni dentro de los splits ni entre ellos. Esto reduce una fuente conocida de data leakage.

Sin embargo, este procedimiento únicamente permite detectar archivos idénticos byte a byte. El dataset no incluye información geográfica auxiliar suficiente para reconstruir de forma confiable relaciones espaciales entre imágenes, por lo que no es posible descartar completamente la existencia de zonas cercanas o visualmente similares.

En caso de detectarse duplicados exactos en versiones posteriores del dataset, estos deberán mantenerse dentro del mismo subconjunto experimental.

4.4 Experimentos propuestos

Durante las siguientes etapas se propone desarrollar dos experimentos principales.

El primero consistirá en seleccionar e implementar un algoritmo base de segmentación semántica multiclase. Dicho modelo será entrenado utilizando las siete clases válidas de LoveDA y servirá como referencia para establecer el rendimiento inicial del sistema.

El segundo experimento incorporará la innovación asignada al proyecto: segmentación multiescala. En este caso, el mismo modelo será evaluado utilizando diferentes escalas de entrada y sus resultados serán combinados para producir una predicción final.

Ambos enfoques serán evaluados bajo las mismas condiciones y utilizando las mismas métricas, con el objetivo de determinar si la incorporación de información multiescala produce una mejora respecto del método base.

Tabla 4. Experimentos propuestos

Experimento	Descripción	Resultado
E1	Algoritmo base de segmentación semántica	Máscara multiclase
E2	Algoritmo base + segmentación multiescala	Máscara multiclase combinada
Comparación	E1 vs. E2	Diferencia en métricas

5. Innovación propuesta

5.1 Determinación de la innovación

De acuerdo con la fórmula establecida para determinar la innovación, se utiliza el primer integrante del grupo en orden lexicográfico. En este caso, el primer integrante es Álvaro, por lo que se considera la letra A = 1.

$$\text{Innovación} = (1 \bmod 2) + 1 = 2$$

Por lo tanto, para el Tema 3 — LoveDA corresponde la Innovación 2: Segmentación multiescala [1].

5.2 Segmentación multiescala

La segmentación multiescala busca incorporar información obtenida a diferentes resoluciones de una misma imagen. La idea consiste en generar predicciones utilizando distintas escalas de entrada, llevar posteriormente las salidas a una resolución común y combinar los mapas de predicción mediante algún mecanismo de fusión.

El documento del proyecto propone realizar esta combinación mediante promedio o votación. En esta primera entrega no se define todavía qué escalas específicas se utilizarán ni cuál será el método de combinación definitivo, ya que estas decisiones deberán evaluarse una vez implementado el algoritmo base [1].

Esta innovación resulta especialmente pertinente para LoveDA, ya que los propios autores del dataset identifican la presencia de objetos multiescala como uno de sus principales desafíos [2].

La comparación final se realizará entre el modelo base y el mismo modelo utilizando segmentación multiescala, manteniendo constantes los demás componentes del experimento. De esta manera será posible atribuir de forma más clara cualquier diferencia de rendimiento al uso de la innovación.

6. Métricas de evaluación

6.1 Intersection over Union

Intersection over Union (IoU) mide el grado de superposición entre los píxeles predichos para una clase y los píxeles pertenecientes a esa misma clase en la máscara de referencia [5].

Para una clase c , se define como:

$$IoU_c = \frac{TP_c}{TP_c + FP_c + FN_c}$$

donde:

- TP_c : píxeles correctamente predichos como clase c ;
- FP_c : píxeles predichos como clase c que pertenecen a otra categoría;
- FN_c : píxeles de la clase c que fueron clasificados como otra categoría.

El valor de IoU se encuentra entre 0 y 1, donde valores más cercanos a 1 representan una mayor coincidencia entre la predicción y el ground truth.

6.2 Mean Intersection over Union

Debido a que LoveDA considera siete clases semánticas, resulta conveniente utilizar además el promedio de IoU entre todas las clases válidas. Esta métrica se conoce como mean Intersection over Union (mIoU).

$$mIoU = \frac{1}{C} \sum_{c=1}^C IoU_c$$

donde $C=7$ corresponde al número de clases semánticas válidas evaluadas.

El valor 0 de las máscaras no será considerado al calcular esta métrica, ya que corresponde a regiones no-data que deben ser ignoradas durante la evaluación.

El uso de mIoU permite resumir en un único valor el rendimiento entre todas las categorías, evitando depender exclusivamente del número total de píxeles de cada clase.

6.3 Dice / F1 Score

Como segunda familia de evaluación se utilizará Dice Score, equivalente al F1 Score cuando se calcula por clase a nivel de píxel [5]. Esta métrica cuantifica la superposición entre la predicción y la máscara de referencia. Para una clase c , se define como

$$Dice_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}$$

Al igual que IoU, Dice toma valores entre 0 y 1, donde valores más cercanos a 1 representan una mayor coincidencia entre la predicción y la referencia. Se propone reportar Dice por clase y un promedio macro entre las siete categorías válidas, excluyendo los píxeles con valor 0.

6.4 Consideraciones sobre la evaluación

Las métricas serán calculadas únicamente sobre píxeles válidos, excluyendo las regiones identificadas con valor 0. Además de los promedios generales, se reportarán resultados por clase debido a que el análisis exploratorio mostró una distribución desigual de píxeles entre las distintas categorías.

Pixel accuracy podría utilizarse posteriormente como información complementaria, pero no se utilizará como métrica principal, ya que un valor global elevado podría ocultar un bajo rendimiento en clases menos representadas.

7. Conclusiones y trabajo futuro

7.1 Conclusiones

En esta primera etapa se realizó la caracterización y preparación del dataset LoveDA para abordar el problema de segmentación semántica multiclase. El análisis permitió verificar la estructura de los datos, la correspondencia entre imágenes y máscaras, las clases disponibles y el tratamiento del valor 0 como región *no-data*.

Se identificaron 5.987 imágenes de 1024×1024 píxeles distribuidas entre Train, Val y Test y entre los dominios Rural y Urban. De ellas, 4.191 poseen máscaras disponibles localmente, mientras que las 1.796 imágenes de Test no incluyen *ground truth*, de acuerdo con el esquema oficial del dataset. No se detectaron imágenes o máscaras corruptas, etiquetas inesperadas, incompatibilidades de dimensiones ni duplicados exactos.

El análisis exploratorio evidenció una distribución desigual de las clases. *Background* y *agriculture* concentran una parte importante de los píxeles válidos, mientras que *road* y *barren* presentan menor representación. También se observaron diferencias entre los dominios: *building* y *road* tienen mayor presencia relativa en Urban, mientras que *agriculture* y *forest* presentan una mayor proporción en Rural. Además, aproximadamente un 3,31% de los píxeles de las máscaras corresponde a regiones *no-data*, las cuales deberán excluirse de la evaluación.

A partir de estos resultados se definió un protocolo experimental que utilizará una división reproducible del Train oficial para entrenamiento y validación interna, mantendrá Val como evaluación local independiente y reservará Test para evaluación externa. Las métricas principales serán IoU por clase, mIoU y Dice/F1. Como todavía no se ha implementado un modelo, esta entrega no permite evaluar rendimiento; su resultado principal es dejar una base de datos y un procedimiento experimental reproducibles para las siguientes etapas.

7.2 Trabajo futuro

La siguiente etapa consistirá en seleccionar e implementar un algoritmo base de segmentación semántica. Antes del entrenamiento se deberán definir el preprocesamiento, normalización, posibles técnicas de *data augmentation*, función de pérdida, optimizador e hiperparámetros. También se materializará la división interna propuesta del conjunto Train, utilizando una semilla fija y procurando conservar una representación adecuada de los dominios Urban y Rural.

El modelo base será evaluado mediante IoU por clase, mIoU y Dice/F1, complementando las métricas con ejemplos visuales de las máscaras obtenidas. Debido a las diferencias observadas entre Rural y Urban, también será útil analizar el rendimiento de manera separada por dominio.

Posteriormente se incorporará la innovación asignada, correspondiente a segmentación multiescala. Para ello se evaluará el modelo sobre diferentes resoluciones y se combinarán los mapas de predicción mediante el mecanismo que se determine experimentalmente. La comparación entre el método base y su variante multiescala se realizará bajo el mismo protocolo, permitiendo determinar a partir de resultados reales si la innovación mejora la segmentación y qué costo adicional introduce.

REFERENCIAS

- [1] B. Peralta, Visión Artificial – Proyecto, Universidad Andrés Bello, 2026.
- [2] J. Wang, Z. Zheng, A. Ma, X. Lu and Y. Zhong, “LoveDA: A Remote Sensing Land-Cover Dataset for Domain Adaptive Semantic Segmentation,” Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks, vol. 1, 2021.
- [3] J. Wang et al., LoveDA: A Remote Sensing Land-Cover Dataset for Domain Adaptive Semantic Segmentation, Zenodo, 2021. doi: 10.5281/zenodo.5706578.
- [4] J. Wang et al., “LoveDA,” GitHub, repositorio oficial del proyecto.
- [5] A. A. Taha and A. Hanbury, “Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool,” BMC Medical Imaging, vol. 15, art. 29, 2015.